Proyecto de Bases de datos

Diana Isabel Arévalo Durán Universidad Central Maestría en Analítica de Datos

Maestria en Analitica de Datos Curso de Bases de Datos Bogotá, Colombia

darevalod@ucentral.edu.co

October 21, 2022

Contents

| 1 Introducción | | | | | | |
|----------------|------------------------------------------------------|-------------------------------------------------------------------|----|--|--|--|
| 2 | Características del proyecto | | | | | |
| | 2.1 | Titulo del proyecto | 3 | | | |
| | 2.2 | Objetivo general | 3 | | | |
| | | 2.2.1 Objetivos especificos | 3 | | | |
| | 2.3 | Alcance | 4 | | | |
| | 2.4 | Pregunta de investigación | 4 | | | |
| | 2.5 | Hipotesis | 4 | | | |
| 3 | Reflexiones sobre el origen de datos e información 5 | | | | | |
| | 3.1 | ¿Cual es el origen de los datos e información? | - | | | |
| | 3.2 | ¿Cuales son las consideraciones legales o eticas del uso de la | | | | |
| | | información? | 5 | | | |
| | 3.3 | ¿Cuales son los retos de la información y los datos que utilizara | | | | |
| | | en la base de datos en terminos de la calidad y la consolidación? | 6 | | | |
| | 3.4 | ¿Que espera de la utilización de un sistema de Bases de Datos | | | | |
| | | para su proyecto? | 6 | | | |
| 4 | Dis | eño del Modelo de Datos del SMBD (Sistema Manejador de | | | | |
| • | Bases de Datos) 7 | | | | | |
| | 4.1 | | • | | | |
| | 7.1 | para el proyecto | 7 | | | |
| | 4.2 | Diagrama modelo de datos | 7 | | | |
| | 4.3 | Imágenes de la Base de Datos | 8 | | | |
| | 4.4 | Código SQL - lenguaje de definición de datos (DDL) | 11 | | | |
| | $\frac{4.4}{4.5}$ | - · · · · · · · · · · · · · · · · · · · | 14 | | | |
| | 4.0 | Código SQL - Manipulación de datos (DML) | 14 | | | |

| | 4.6 Código SQL + Resultados: Vistas | 16 |
|---|----------------------------------------------------------------------|----|
| | 4.7 Código SQL + Resultados: Triggers | 16 |
| | 4.8 Código SQL + Resultados: Funciones | 17 |
| | 4.9 Código SQL + Resultados: procedimientos almacenados | 17 |
| 5 | Bases de Datos No-SQL (Segunda entrega) | 18 |
| | 5.1 Diagrama Bases de Datos No-SQL (Segunda entrega) | 18 |
| | 5.2 SMBD utilizado para la Base de Datos No-SQL (Segunda entrega) | 18 |
| 6 | Aplicación de ETL (Extract, Transform, Load) y Bodega de | |
| | Datos (Tercera entrega) | 19 |
| | 6.1 Ejemplo de aplicación de ETL y Bodega de Datos (Tercera entrega) | 19 |
| 7 | Lecciones aprendidas (Tercera entrega) | 20 |
| | | |

1 Introducción

El presente trabajo se realiza con base en los datos recolectados en la gran encuesta de los hogares Colombianos 2020, con el objetivo de predecir la probabilidad de que los niños de Colombia, menores de 12 años al 2020, en el futuro accedan a educación superior o universitaria.

Para esto, inicialmente se realiza normalización de la base de datos obtenida del Archivo Nacional de Datos (ANDA) que permite la consulta por temática, operación estadística y año, de los diferentes microdatos anonimizados dispuestos al público en la página web del DANE, haciendo uso del sistema manejador de base de datos MySQL.

Posteriormente se aplican métodos de estadística exploratoria multidimensional, resumiendo el conjunto de variables en unas pocas nuevas variables, buscando agrupaciones en los datos y clasificando para identificar relaciones entre variables. Finalmente se contrastan los resultados contra la hipótesis planteada.

2 Características del proyecto

2.1 Titulo del proyecto

Predicción de la probabilidad que tienen los niños de los hogares colombianos menores de 12 años al 2020, de acceso a la educación superior, de acuerdo con condiciones de empleo, fuentes de ingreso y caracteristicas generales de los hogares.

2.2 Objetivo general

Predecir la probabilidad de que los niños de Colombia, menores de 12 años al 2020, en el futuro accedan a educación superior o universitaria.

2.2.1 Objetivos especificos

- A través del uso de métodos de reducción de dimensionalidad generar visualizaciones de datos que permitan la fácil comprensión de los datos de la encuesta general de hogares colombianos.
- Por medio de la clasificación y regresión, analizar comportamientos para predecir la probablidad de acceso a educación superior de los niños menores de 12 años.

2.3 Alcance

El alcance de este proyecto será la predicción probabilidad de que los niños de Colombia, menores de 12 años al 2020, en el futuro accedan a educación superior o universitaria.

2.4 Pregunta de investigación

Entre 0 y 12 años ¿Qué probabilidad tienen los niños de los hogares colombianos de la Gran encuesta integrada de hogares 2020, de acceder a la educación superior o universitaria de acuerdo con condiciones de empleo, fuentes de ingreso y caracteristicas generales de los hogares?.

2.5 Hipotesis

La probabilidad de acceso a la educación superior o universitaria de los niños en Colombia está determinada por el nivel educativo de los padres.

3 Reflexiones sobre el origen de datos e información

La Gran encuesta integrada de hogares es una encuesta mediante la cual se solicita información sobre las condiciones de empleo de las personas, además de las características generales de la población como sexo, edad, estado civil y nivel educativo, se pregunta sobre sus fuentes de ingresos. Esta encuesta proporciona indicadores a nivel nacional del mercado laboral en Colombia que permiten conocer entre otros aspectos: la tasa de ocupación, la tasa de desocupación, la rama de actividad en que se desempeñan los colombianos y su remuneración, así como, el comportamiento del mercado laboral para jóvenes, mujeres y otros grupos poblacionales específicos.

3.1 ¿Cual es el origen de los datos e información?

Los datos corresponden a la Gran Encuesta Integrada de Hogares Colombianos 2020 realizada por el Departamento Administrativo Nacional de Estadística - DANE, a la población civil no institucional residente en hogares particulares. Esta población se estima con base en los censos de población, las estadísticas vitales y de migración.

Estos datos fueron obtenidos del Archivo Nacional de Datos (ANDA) que permite la consulta por temática, operación estadística y año, de los diferentes microdatos anonimizados dispuestos al público en la página web del DANE.

3.2 ¿Cuales son las consideraciones legales o eticas del uso de la información?

Toda la información recolectada para los censos y encuestas de los procesos estadísticos del DANE está protegida por la Ley 79 de 1993 o Ley de Reserva Estadística.

Según esta ley los datos suministrados al DANE a través de censos, encuestas u operaciones estadísticas "no podrán darse a conocer al público ni a las entidades u organismos oficiales, ni a las autoridades públicas, sino únicamente en resúmenes numéricos".

En consonancia con la Ley 1581 de 2012, las bases de datos y archivos regulados por la Ley 79 de 1993 están exceptuadas del régimen de protección de datos personales. Sin embargo, deben aplicarse los principios establecidos para su protección como son: el principio de legalidad en materia de tratamiento de datos, de finalidad, de libertad, de veracidad o calidad, de transparencia, de acceso y circulación restringida, de seguridad y de confidencialidad.

Por lo anterior, las bases anonimizadas y disponibles en el ANDA han surtido un proceso de modificación y transformación de los datos originales, con el

objetivo de garantizar la confidencialidad de las unidades de análisis, por lo cual es necesario tener en cuenta estas modificaciones para el uso de la información.

3.3 ¿Cuales son los retos de la información y los datos que utilizara en la base de datos en terminos de la calidad y la consolidación?

Los datos obtenidos están representados con variables categóricas y el nombre de estas es dado con códigos, por lo que se debe realizar listas de homologación tanto para los nombres como para las categorías, con el objetivo de poder generar información sencilla y entendible.

Debido a que las bases publicadas por el DANE se encuentran anonimizadas y han surtido un proceso de modificación y transformación de los datos originales, la estructura de la base, entregada en el documento técnico de la DIAN, no corresponde con la publicada en la página, es por esto que se debe trabajar en la identificación de variables y homologaciones disponibles.

3.4 ¿Que espera de la utilización de un sistema de Bases de Datos para su proyecto?

Se hace uso del sistema de base de datos con el objetivo de organizar los datos obtenidos para poder acceder a búsquedas eficientes y consultas simplificadas que puedan ser reutilizadas.

Del sistema se espera extraer bases de datos unificadas con las variables más importantes de la operación estadística para realizar análisis de correspondencia.

4 Diseño del Modelo de Datos del SMBD (Sistema Manejador de Bases de Datos)

4.1 Características del SMBD (Sistema Manejador de Bases de Datos) para el proyecto

El Sistema Manejador de Bases de Datos utilizado para el proyecto es MySQL y dentro de sus principales caracteristicas están:

- Sistema de base de datos relacional de uso libre y gratuito.
- Soporta gran cantidad de datos, incluso con más de 50 millones de registros.
- Ejecución de transacciones y uso de claves foráneas.
- Conectividad segura.

4.2 Diagrama modelo de datos

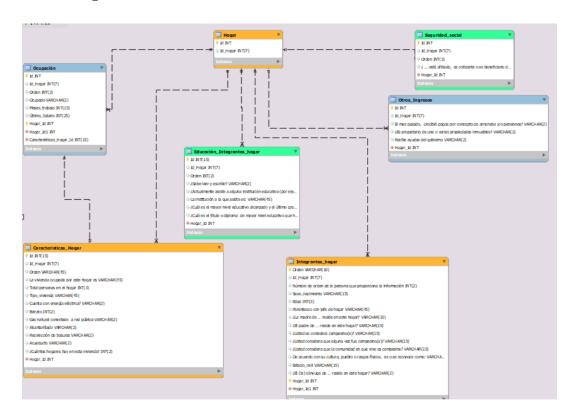


Figure 1: Diagrama Entidad Relación

4.3 Imágenes de la Base de Datos

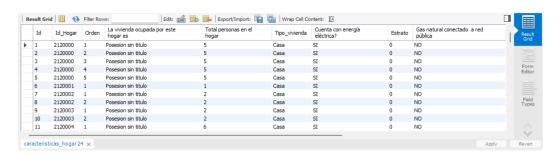


Figure 2: Caracteristicas hogar

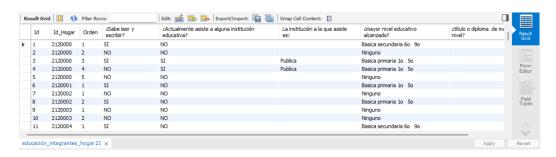


Figure 3: Educación integrantes hogar

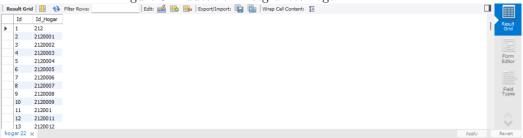


Figure 4: Hogar

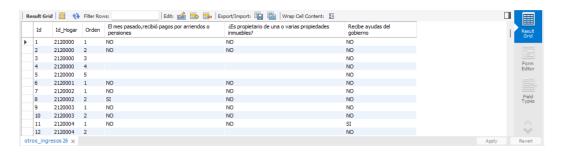


Figure 5: Otros ingresos

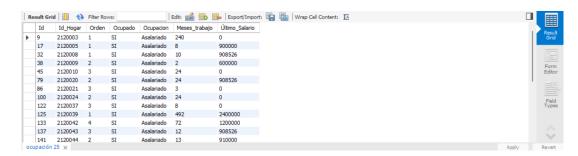


Figure 6: Ocupación

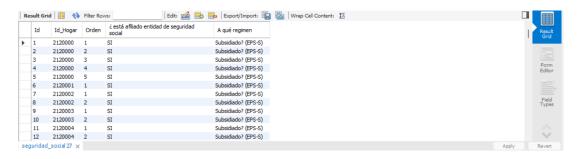


Figure 7: Seguridad Social

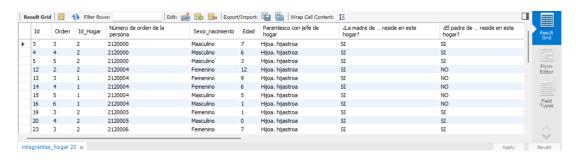


Figure 8: Integrantes hogar

4.4 Código SQL - lenguaje de definición de datos (DDL)

```
21
       -- Table `mydb`.`Hogar`
23
24 • 

○ CREATE TABLE IF NOT EXISTS `Encuesta_hogares`.`Hogar` (
25
       'Id' INT NOT NULL AUTO_INCREMENT,
        `Id_Hogar` INT(7) NULL,
26
       PRIMARY KEY ('Id'))
27
      ENGINE = InnoDB;
28
30
31
32
       -- Table `mydb`.`Integrantes_hogar`
33
34 • ○ CREATE TABLE IF NOT EXISTS `Encuesta_hogares`.`Integrantes_hogar` (
35
        'Id' INT NOT NULL AUTO INCREMENT,
36
         `Orden` VARCHAR(10) NULL,
        `Id_Hogar` INT(7) NULL,
37
        `Número de orden de la persona que proporciona la información` INT(2) NULL,
38
        `Sexo_nacimiento` VARCHAR(15) NULL,
        `Edad` INT(3) NULL,
40
         `Parentesco con jefe de hogar` VARCHAR(45) NULL,
41
42
         `¿La madre de ... reside en este hogar?` VARCHAR(15) NULL,
         `¿El padre de ... reside en este hogar?` VARCHAR(15) NULL,
43
44
         `¿Usted se considera campesino(a)?` VARCHAR(15) NULL,
         `¿Usted considera que alguna vez fue campesino(a)?` VARCHAR(15) NULL,
45
          `¿Usted considera que la comunidad en que vive es campesina?` VARCHAR(15) NULL,
46
47
         `De acuerdo con su cultura se reconoce como: VARCHAR(45) NULL,
         `Estado civil` VARCHAR(15) NULL,
48
         `¿El (la) cónyuge de ... reside en este hogar?` VARCHAR(2) NULL,
         `Hogar_Id` INT NOT NULL,
50
51
         `Hogar_Id1` INT NOT NULL,
52
         PRIMARY KEY ('Id', 'Hogar_Id'),
        CONSTRAINT `fk_Integrantes_hogar_Hogar1`
53
54
          FOREIGN KEY ('Hogar_Id1')
          REFERENCES `mydb`.`Hogar` (`Id`)
55
           ON DELETE NO ACTION
57
          ON UPDATE NO ACTION)
      ENGINE = InnoDB;
58
```

```
-- Table `Encuesta_hogares`.`Caracteristicas_Hogar`
64
65 • ○ CREATE TABLE IF NOT EXISTS `Encuesta_hogares`.`Caracteristicas_Hogar` (
 66
         'Id' INT(15) NOT NULL AUTO_INCREMENT,
         `Id_Hogar` INT(7) NULL,
67
 68
         `Orden` VARCHAR(45) NULL,
         `La vivienda ocupada por este hogar es` VARCHAR(45) NULL,
69
         'Total personas en el hogar' INT(3) NULL,
 70
         `Tipo_vivienda` VARCHAR(45) NULL,
 71
         `Cuenta con energía eléctrica?` VARCHAR(2) NULL,
 72
 73
         `Estrato` INT(2) NULL,
         `Gas natural conectado a red pública` VARCHAR(2) NULL,
 74
 75
         `Alcantarillado` VARCHAR(2) NULL,
         `Recolección de basuras` VARCHAR(2) NULL,
 76
 77
        `Acueducto` VARCHAR(2) NULL,
 78
         `¿Cuántos hogares hay en esta vivienda?` INT(2) NULL,
         `Hogar_Id` INT NOT NULL,
 79
 80
         PRIMARY KEY ('Id'),
        CONSTRAINT `fk_Caracteristicas_Hogar_Hogar1`
81
          FOREIGN KEY (`Hogar_Id`)
82
83
          REFERENCES `mydb`.`Hogar` (`Id`)
          ON DELETE NO ACTION
 84
 85
          ON UPDATE NO ACTION)
     ENGINE = InnoDB;
 86
91
         -- Table `Encuesta_hogares`.`Seguridad_social`
92
93 • 

○ CREATE TABLE IF NOT EXISTS `Encuesta_hogares`.`Seguridad_social` (
          'Id' INT NOT NULL AUTO_INCREMENT,
94
          `Id_Hogar` INT(7) NULL,
95
96
          `Orden` INT(3) NULL,
97
          '¿ está afiliado entidad de seguridad social' VARCHAR(45) NULL,
          `A qué regimen` VARCHAR(45) NULL,
98
          'Hogar_Id' INT NOT NULL,
99
          PRIMARY KEY ('Id'),
100
          CONSTRAINT `fk_Seguridad_social_Hogar1`
101
102
            FOREIGN KEY ('Hogar_Id')
103
            REFERENCES `mydb`.`Hogar` ('Id')
            ON DELETE NO ACTION
104
            ON UPDATE NO ACTION)
105
      ENGINE = InnoDB;
106
```

```
111
        -- Table `Encuesta_hogares`.`Educación_Integrantes_hogar`
112
113 • ⊖ CREATE TABLE IF NOT EXISTS `Encuesta_hogares`.`Educación_Integrantes_hogar` (
          'Id' INT(15) NOT NULL AUTO_INCREMENT,
114
115
         `Id_Hogar` INT(7) NULL,
         `Orden` INT(2) NULL,
116
          '¿Sabe leer y escribir?' VARCHAR(2) NULL,
117
118
          `¿Actualmente asiste a alguna institución educativa?` VARCHAR(2) NULL,
         `La institución a la que asiste es:` VARCHAR(45) NULL,
119
         `¿mayor nivel educativo alcanzado?` VARCHAR(45) NULL,
121
         `¿título o diploma de mayor nivel educativo?` VARCHAR(45) NULL,
          `Hogar_Id` INT NOT NULL,
122
123
          PRIMARY KEY ('Id'),
         CONSTRAINT `fk_Educación_Integrantes_hogar_Hogar1`
124
125
          FOREIGN KEY ('Hogar_Id')
           REFERENCES `mydb`.`Hogar` (`Id`)
126
127
           ON DELETE NO ACTION
128
          ON UPDATE NO ACTION)
129
        ENGINE = InnoDB;
134
        -- Table `Encuesta_hogares`.`Ocupación`
135
136 • ⊝ CREATE TABLE IF NOT EXISTS `mydb`.`Ocupación` (
          'Id' INT NOT NULL,
137
138
          'Id_Hogar' INT(7) NULL,
         `Orden` INT(2) NULL,
139
140
         `Ocupado` VARCHAR(2) NULL,
          `Meses_trabajo` INT(15) NULL,
141
142
          `Último_Salario` INT(25) NULL,
143
          `Hogar_Id` INT NOT NULL,
          `Hogar_Id1` INT NOT NULL,
144
145
          `Caracteristicas_Hogar_Id` INT(15) NOT NULL,
          PRIMARY KEY ('Id', 'Hogar_Id'),
146
147
          CONSTRAINT `fk_Ocupación_Hogar`
148
           FOREIGN KEY (`Hogar_Id1`)
           REFERENCES `mydb`.`Hogar` (`Id`)
149
150
           ON DELETE NO ACTION
151
           ON UPDATE NO ACTION,
          CONSTRAINT `fk_Ocupación_Caracteristicas_Hogar1`
152
153
           FOREIGN KEY (`Caracteristicas_Hogar_Id`)
           REFERENCES `mydb`.`Caracteristicas_Hogar` (`Id`)
154
155
            ON DELETE NO ACTION
           ON UPDATE NO ACTION)
156
        ENGINE = InnoDB;
```

```
-- Table `Encuesta_hogares`.`Otros_Ingresos`
161
162
163 • 

○ CREATE TABLE IF NOT EXISTS `Encuesta_hogares`.`Otros_Ingresos` (
          'Id' INT NOT NULL,
164
165
          `Id_Hogar` INT(7) NULL,
           `¿recibió pagos por concepto de arriendos, pensiones?` VARCHAR(2) NULL,
166
          `¿Es propietario de una o varias propiedades inmuebles?` VARCHAR(2) NULL,
167
          `Recibe ayudas del gobierno` VARCHAR(2) NULL,
168
          'Hogar Id' INT NOT NULL,
169
170
          PRIMARY KEY ('Id'),
          CONSTRAINT `fk_Otros_Ingresos_Hogar1`
171
           FOREIGN KEY ('Hogar_Id')
173
           REFERENCES `mydb`.`Hogar` (`Id`)
174
            ON DELETE NO ACTION
175
           ON UPDATE NO ACTION)
176
        ENGINE = InnoDB;
177
178
179 •
       SET SQL_MODE=@OLD_SQL_MODE;
180 •
       SET FOREIGN_KEY_CHECKS=@OLD_FOREIGN_KEY_CHECKS;
181 • SET UNIQUE_CHECKS=@OLD_UNIQUE_CHECKS;
```

4.5 Código SQL - Manipulación de datos (DML)

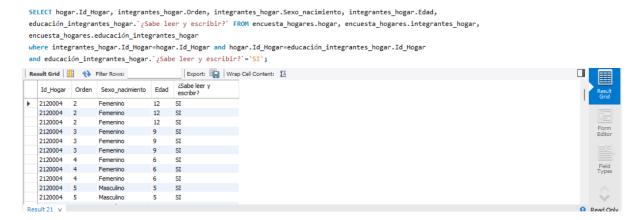


Figure 9: Sentencia 1

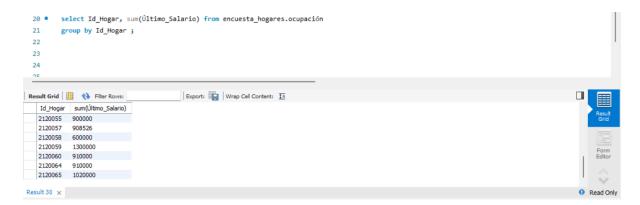


Figure 10: Sentencia 2



Figure 11: Sentencia 3

4.6 Código SQL + Resultados: Vistas

Figure 12: Vista 1

4.7 Código SQL + Resultados: Triggers



Figure 13: Trigger 1

4.8 Código SQL + Resultados: Funciones

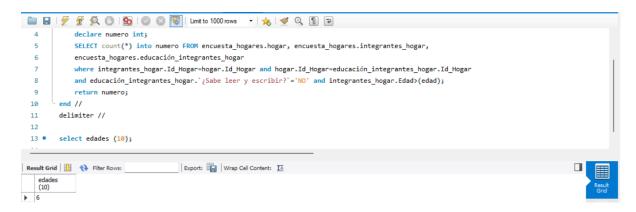


Figure 14: Función 1

4.9 Código SQL + Resultados: procedimientos almacenados

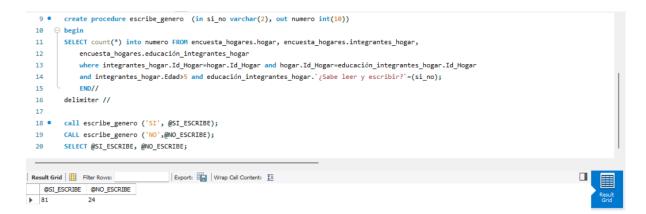


Figure 15: Procedimiento 1

- 5 Bases de Datos No-SQL (Segunda entrega)
- 5.1 Diagrama Bases de Datos No-SQL (Segunda entrega)
- 5.2 SMBD utilizado para la Base de Datos No-SQL (Segunda $_{entrega)}$

- 6 Aplicación de ETL (Extract, Transform, Load) y Bodega de Datos (Tercera entrega)
- 6.1 Ejemplo de aplicación de ETL y Bodega de Datos (Tercera entrega)

7 Lecciones aprendidas (Tercera entrega)

References

LAZARO (2019) Cómo crear y usar una función almacenada MySQL Obtenido de https://www.neoguias.com/funciones-almacenadas-mysql/: :text=Las

SANCHEZ 2022 Triggers, procedimientos y funciones en MySQL Obtenido de https://josejuansanchez.org/bd/unidad-12-teoria/index.htmlfunciones

DANE (2021) Gran Encuesta Integrada de Hogares Obtenido de http://microdatos.dane.gov.co/index.php/catalog/MICRODATOS/about_collection/23/1

DANE Consideraciones para el uso de la información Obtenido de https://microdatos.dane.gov.co/home